


Predicción de resistencia antimicrobiana en *Escherichia coli* mediante aprendizaje automático basado en genes AMR

Alan Yael Díaz Mora
Juan Ramón Franco Anaya
Soo Yeon Kim
Jimena Ugalde Flores


INTRODUCCIÓN

- La resistencia antimicrobiana reduce la eficacia de antibióticos usados contra infecciones bacterianas.
- En 2023, 1 de cada 6 infecciones bacterianas confirmadas en laboratorio fue resistente
- Entre 2018 y 2023 la resistencia aumentó en más del 40% de los casos monitoreados
- *E. coli* es un modelo útil porque causa infecciones frecuentes, tiene muchos genomas disponibles y puede adquirir genes AMR.



JUSTIFICACIÓN

- Las pruebas AST son necesarias, pero pueden requerir horas o días.
- Los genomas bacterianos contienen señales asociadas con resistencia, como genes AMR y variantes en blancos del antibiótico.
- Ciprofloxacin y cefotaxime representan mecanismos distintos: fluoroquinolonas vs β -lactámicos.
- ML permite comparar si esos perfiles genómicos clasifican genomas como resistentes o susceptibles.



OBJETIVO

- Evaluar si la presencia o ausencia de genes AMR permite clasificar genomas de *E. coli* como resistentes o susceptibles a ciprofloxacina y cefotaxima mediante modelos de aprendizaje automático supervisado.

HIPÓTESIS INICIAL

- Los modelos basados en árboles, como random forest y XGBoost, tendrían mejor desempeño que la regresión logística al capturar relaciones no lineales entre variables genómicas.

DISEÑO

- Descarga de datos
- Filtrado y Limpieza
- Construcción de matrices
- Entrenamiento de modelos
- Evaluación de modelos

Flujo general del análisis



DISEÑO:

DESCARGA DE DATOS

- Bacterial and Viral Bioinformatics Resource Center
- Ciprofloxacino y Cefotaxima
- Perfil Genético de la categoría Antibiotic Resistance



DISEÑO: FILTRADO Y LIMPIEZA

- Calidad del Fenotipo
- Resolución de Conflictos
- Optimización de variables



DISEÑO: CONSTRUCCIÓN DE MATRICES

- Matriz Binaria
- Unión de Datos

Antibiótico	Genomas totales	Resistentes	Susceptibles	Genes AMR model_ready
Ciprofloxacin	7,313	1,851	5,462	633
Cefotaxime	6,590	1,272	5,318	560

genome_id (Bacterias individuales)	amr__aac3-ii (Gen 1)	amr__gyrA (Gen 2)	...	amr__ctx-m-14 (Gen P)	y
Genome 1	1	0	...	1	1 (Resistente)
Genome 2	0	0	...	0	0 (Susceptible)
Genome N	0	1	...	0	1 (Resistente)

DISEÑO:


ENTRENAMIENTO & EVALUACIÓN DE MODELOS

- División de Datos
- Algoritmos :
 - Regresión Logística
 - Random Forest
 - XGBoost
 - MLP
- Validación Cruzada
- Métricas de Desempeño
- Interpretación Biológica
- Robustez

RESULTADOS:

RENDIMIENTO DE LOS CUATRO MODELOS EVALUADOS

Antibiótico	Modelo	Balanced accuracy	ROC-AUC
Ciprofloxacina	Regresión logística balanceada	0.844	0.906
Ciprofloxacina	Random forest balanceado	0.837	0.922
Ciprofloxacina	XGBoost ponderado	0.836	0.907
Ciprofloxacina	MLP ponderado	0.835	0.903
Cefotaxime	Regresión logística balanceada	0.827	0.893
Cefotaxime	Random forest balanceado	0.791	0.879
Cefotaxime	XGBoost ponderado	0.810	0.886
Cefotaxime	MLP ponderado (promedio 7 semillas)	0.818	0.893





La balanced accuracy es el promedio del acierto en resistentes y susceptibles. Se seleccionó regresión logística como modelo principal por su mayor balanced accuracy en ambos antibióticos (0.844 y 0.827).

RESULTADOS:

ERRORES DEL MODELO

Falso susceptible = genoma resistente clasificado como susceptible (error más crítico).


El MLP reduce falsos susceptibles, pero aumenta falsos resistentes.



RESULTADOS:

TOP 10 GENES AMR MÁS ESTABLES – CIPROFLOXACIN

Aparecen genes clásicos de resistencia a quinolonas junto con señales de otros antibióticos (co-resistencia).




Gen/señal	Observación
parC	Blanco de quinolonas
gyrA	Blanco de quinolonas
parE	Subunidad de topoisomerasa IV
ctx-m-15	Gen de β-lactamasa (co-resistencia)
blaEC	Asociado a multirresistencia

RESULTADOS:

TOP 10 GENES AMR MÁS ESTABLES – CEFOTAXIME

Dominado por genes de β -lactamasas (CTX-M y CMY), mecanismo principal de resistencia a cefalosporinas de 3ª generación




Gen/familia	Tipo de mecanismo
ctx-m-15	β -lactamasa ESBL
ctx-m_family	Familia CTX-M
ctx-m-14	β -lactamasa ESBL
cmy-2	β -lactamasa AmpC
blaEC	Asociado a resistencia

RESULTADOS:

¿EL MODELO GENERALIZA A DISTINTOS MÉTODOS FENOTÍPICOS?


El desempeño se mantiene en rangos aceptables, aunque varía según el método. El escenario más difícil: cefotaxime evaluado en broth dilution (0.768).

Antibiótico	Método excluido	Balanced accuracy	ROC-AUC
Ciprofloxacin	Broth dilution	0.786	0.858
	Disk diffusion	0.815	0.869
	MIC	0.813	0.863
Cefotaxime	Agar dilution	0.821	0.878
	Broth dilution	0.768	0.829
	Disk diffusion	0.801	0.848



ANÁLISIS: COMPARACIÓN DE MODELOS

- Todos los modelos superaron el 50% de precisión esperada
- Regresión Logística (RL) fue el más consistente e interpretable
- Fue más fácil predecir bacterias susceptibles que resistentes



INTERPRETACION BIOLOGICA

- Cefotaxima (Señal directa): Modelo detectó genes de β -lactamasas [ctx-m, cmy-2]. La estrategia de "presencia/ausencia" funciona perfecto.
- Ciprofloxacino (Señal indirecta): Modelo detectó blancos (gyrA, parC), pero también captó ruido.
- Una variable predictiva en IA no siempre es el mecanismo causal biológico.



RETOS Y LIMITACIONES



- Prueba Leave-method-out: El rendimiento baja porque los métodos de laboratorio (ej. dilución vs. difusión) miden la resistencia con criterios distintos.
- Reducir el ADN a "presencia/ausencia" omite mutaciones puntuales y expresión de genes.

REFERENCIAS

- Bevan, E. R., Jones, A. M., & Hawkey, P. M. (2017). Global epidemiology of CTX-M β -lactamases: Temporal and geographical shifts in genotype. *Journal of Antimicrobial Chemotherapy*, 72(8), 2145–2155. <https://doi.org/10.1093/jac/dkx146>
- Bush, K., & Bradford, P. A. (2016). β -Lactams and β -lactamase inhibitors: An overview. *Cold Spring Harbor Perspectives in Medicine*, 6(8), a025247. <https://doi.org/10.1101/cshperspect.a025247>
- Centers for Disease Control and Prevention. (2024). *About Escherichia coli infection*. <https://www.cdc.gov/ecoli/about/index.html>
- European Centre for Disease Prevention and Control. (2025). *Surveillance of antimicrobial resistance in Europe, 2024 data*. ECDC. <https://www.ecdc.europa.eu/en/publications-data/surveillance-antimicrobial-resistance-europe-2024-data>
- European Committee on Antimicrobial Susceptibility Testing. (2024). *Breakpoint tables for interpretation of MICs and zone diameters: Version 14.0*. EUCAST. <https://www.eucast.org>
- Feldgarden, M., Brover, V., Gonzalez-Escalona, N., Frye, J. G., Haendiges, J., Haft, D. H., Hoffmann, M., Pettengill, J. B., Prasad, A. B., Tillman, G. E., Tyson, G. H., & Klimke, W. (2021). AMRFinderPlus and the Reference Gene Catalog facilitate examination of the genomic links among antimicrobial resistance, stress response, and virulence. *Scientific Reports*, 11, 12728. <https://doi.org/10.1038/s41598-021-91456-0>
- Her, H.-L., & Wu, Y.-W. (2018). A pan-genome-based machine learning approach for predicting antimicrobial resistance activities of the *Escherichia coli* strains. *Bioinformatics*, 34(13), i89–i95. <https://doi.org/10.1093/bioinformatics/bty276>
- Hooper, D. C., & Jacoby, G. A. (2016). Topoisomerase inhibitors: Fluoroquinolone mechanisms of action and resistance. *Cold Spring Harbor Perspectives in Medicine*, 6(9), a025320. <https://doi.org/10.1101/cshperspect.a025320>
- Kim, J. I., Maguire, F., Tsang, K. K., Gouliouris, T., Peacock, S. J., McAllister, T. A., McArthur, A. G., & Beiko, R. G. (2022). Machine learning for antimicrobial resistance prediction: Current practice, limitations, and clinical perspective. *Clinical Microbiology Reviews*, 35(3), e00179–21. <https://doi.org/10.1128/cmr.00179-21>
- Nsubuga, M., Galiwango, R., Jjingo, D., & Mboowa, G. (2024). Generalizability of machine learning in predicting antimicrobial resistance in *E. coli*: A multi-country case study in Africa. *BMC Genomics*, 25, 287. <https://doi.org/10.1186/s12864-024-10214-4>
- Olson, R. D., Assaf, R., Brettin, T., Conrad, N., Cucinell, C., Davis, J. J., Dempsey, D. M., Dickerman, A., Dietrich, E. M., Kenyon, R. W., Kuscuoglu, M., Lefkowitz, E. J., Lu, J., Machi, D., Macken, C., Mao, C., Niewiadomska, A., Nguyen, M., Olsen, G. J., ... Scheuermann, R. H. (2023). Introducing the Bacterial and Viral Bioinformatics Resource Center (BV-BRC): A resource combining PATRIC, IRD and ViPR. *Nucleic Acids Research*, 51(D1), D678–D689. <https://doi.org/10.1093/nar/gkac1003>
- Partridge, S. R., Kwong, S. M., Firth, N., & Jensen, S. O. (2018). Mobile genetic elements associated with antimicrobial resistance. *Clinical Microbiology Reviews*, 31(4), e00088–17. <https://doi.org/10.1128/CMR.00088-17>
- Ren, Y., Chakraborty, T., Doijad, S., Falgenhauer, L., Falgenhauer, J., Goesmann, A., Hauschild, A.-C., Schwengers, O., Heider, D., & Sztyler, T. (2022). Prediction of antimicrobial resistance based on whole-genome sequencing and machine learning. *Bioinformatics*, 38(2), 325–334. <https://doi.org/10.1093/bioinformatics/btab681>
- World Health Organization. (2018, February 7). *E. coli*. <https://www.who.int/news-room/fact-sheets/detail/e-coli>
- World Health Organization. (2023). *Antimicrobial resistance*. <https://www.who.int/news-room/fact-sheets/detail/antimicrobial-resistance>
- World Health Organization. (2025). *Global antibiotic resistance surveillance report 2025*. World Health Organization. <https://www.who.int/publications/i/item/9789240116337>