

Predicción de resistencia antimicrobiana en *Escherichia coli* mediante aprendizaje automático basado en genes AMR

Integrantes: Díaz Mora Alan Yael, Soo Yeon Kim, Juan Ramón Franco Anaya, Jimena Ugalde Flores

Introducción

La resistencia a los antibióticos se ha convertido en un problema de salud pública frecuente debido a que algunas bacterias ya no se eliminan tan fácilmente con medicamentos que antes funcionaban. Esto pasa cuando una bacteria logra sobrevivir aunque esté en contacto con un antibiótico. Puede ocurrir porque la bacteria tuvo cambios en su ADN, porque recibió genes de otra bacteria o porque el uso frecuente de antibióticos favorece que sobrevivan las bacterias que ya tenían alguna ventaja. Además, estas bacterias resistentes pueden transmitirse entre personas, animales y ambientes (World Health Organization, 2023; Partridge et al., 2018). La Organización Mundial de la Salud ha señalado que este problema dificulta el tratamiento de infecciones comunes y aumenta los problemas clínicos relacionados con bacterias resistentes (World Health Organization, 2023). También, los reportes de vigilancia como GLASS muestran que la resistencia aparece en diferentes regiones del mundo y en distintas bacterias (World Health Organization, 2025). Debido a esto, revisar el ADN bacteriano puede ayudar a entender qué genes podrían estar relacionados con que una bacteria sea resistente o susceptible.

Una bacteria que se usa comúnmente para estudiar este tema es *Escherichia coli*. Muchas cepas de *E. coli* forman parte normal de la microbiota intestinal y no causan enfermedad, pero otras pueden causar infecciones urinarias, gastrointestinales, intraabdominales o del torrente sanguíneo (World Health Organization, 2018; Centers for Disease Control and Prevention, 2024). Además, esta bacteria puede recibir material genético de otras bacterias por transferencia horizontal, y eso puede incluir genes relacionados con resistencia a antibióticos (Partridge et al., 2018; Bevan et al., 2017). De hecho, la OMS ha reportado niveles altos de resistencia en *E. coli* frente a cefalosporinas de tercera generación y fluoroquinolonas en distintos sistemas de vigilancia (World Health Organization, 2023, 2025). El ECDC también ha señalado que las infecciones en la sangre por *E. coli* resistente a cefalosporinas de tercera generación siguen siendo parte de la vigilancia epidemiológica en Europa (European Centre for Disease Prevention and Control, 2025). Como existen muchos genomas disponibles de esta bacteria y en varios casos también se conoce si fueron resistentes

o susceptibles, *E. coli* puede usarse para estudiar la relación entre genes y respuesta a antibióticos.

En este trabajo se analizaron dos antibióticos: ciprofloxacina y cefotaxima. Ciprofloxacina pertenece al grupo de las fluoroquinolonas. Este tipo de antibióticos afecta enzimas que la bacteria necesita para copiar y mantener su ADN, como la ADN girasa y la topoisomerasa IV (Hooper & Jacoby, 2016). Si estas enzimas se alteran o el antibiótico ya no puede actuar bien sobre ellas, la bacteria puede tener más oportunidad de sobrevivir. Cefotaxima, por su parte, pertenece a las cefalosporinas de tercera generación, que son antibióticos β -lactámicos, los cuales afectan la formación de la pared celular bacteriana (Bush & Bradford, 2016). Ambos antibióticos se han usado contra bacterias Gram negativas como *E. coli*, aunque su efecto puede disminuir cuando la bacteria presenta mecanismos de resistencia.

En ciprofloxacina, la resistencia se ha relacionado con cambios en genes como *gyrA*, *parC* y *parE*. Estos genes tienen información para formar subunidades de las enzimas sobre las que actúa el antibiótico. Cuando hay ciertas mutaciones, el antibiótico puede unirse peor a su blanco y la bacteria puede sobrevivir con más facilidad bajo la presión del medicamento (Hooper & Jacoby, 2016). También existen otros mecanismos, como bombas que expulsan el antibiótico de la célula o genes que pueden llegar por plásmidos y ayudar a resistir quinolonas (Hooper & Jacoby, 2016). En el caso de cefotaxima, un mecanismo conocido es la producción de β -lactamasas. Estas son enzimas que pueden hidrolizar o inactivar antibióticos β -lactámicos, haciendo que el medicamento sea menos eficaz. Algunas de estas enzimas son las β -lactamasas de espectro extendido, o ESBL, y dentro de ellas están las tipo CTX-M, como CTX-M-15 y CTX-M-14. También se han descrito β -lactamasas tipo AmpC, como CMY-2, que pueden participar en la resistencia frente a cefalosporinas (Bevan et al., 2017). Con esto se entiende mejor por qué algunos genes pueden aparecer con más frecuencia en bacterias resistentes.

Actualmente, la información genómica permite estudiar la resistencia bacteriana de una forma más amplia, porque no se revisa solo un gen, sino muchos genes al mismo tiempo. A partir de secuencias genómicas se pueden construir tablas de presencia y ausencia de genes AMR, que después se comparan con fenotipos de resistencia o susceptibilidad (Feldgarden et al., 2021; Olson et al., 2023). Bases de datos y herramientas como AMRFinderPlus de NCBI y BV-BRC/PATRIC son útiles porque reúnen genomas, anotaciones de genes, información de resistencia y otros datos para estudiar bacterias (Feldgarden et al., 2021; Olson et al., 2023). Aun así, que una bacteria tenga un gen AMR no significa automáticamente que será resistente, porque también puede influir si ese gen se expresa, si actúa junto con otros genes o si la cepa

tiene otras características que cambian el resultado (Feldgarden et al., 2021; Kim et al., 2022).

Con estos datos también se puede usar aprendizaje automático supervisado. En este caso, el modelo recibe ejemplos donde ya se sabe la respuesta: por un lado se le dan los genes presentes o ausentes, y por otro se le dice si la cepa fue resistente o susceptible. Con esa información, el modelo busca patrones que ayuden a separar un grupo del otro. En estudios sobre antibióticos se han usado modelos como regresión logística, random forest, gradient boosting y redes neuronales para intentar predecir resistencia a partir de información genética (Kim et al., 2022). De manera similar, en este proyecto, los genes de resistencia se usaron en formato de presencia/ausencia y se compararon varios modelos: regresión logística balanceada, random forest balanceado, XGBoost ponderado y un perceptrón multicapa o MLP. Con esto se buscó revisar si la información genética disponible podía ayudar a clasificar genomas de *E. coli* como resistentes o susceptibles a ciprofloxacina y cefotaxima, sin asumir que el modelo explica todos los factores biológicos que participan.

Objetivo

Evaluar si la presencia o ausencia de genes AMR permite clasificar genomas de *Escherichia coli* como resistentes o susceptibles a ciprofloxacina y cefotaxima usando modelos de aprendizaje automático supervisado.

También se buscó construir tablas de presencia/ausencia de genes para ambos antibióticos, comparar distintos modelos de clasificación y revisar si los genes más influyentes coincidían con mecanismos conocidos de resistencia a fluoroquinolonas y cefalosporinas de tercera generación.

Diseño

El flujo general de descarga, filtrado, construcción de matrices, entrenamiento y evaluación de modelos se muestra en la Figura 1.

Primero, se construyeron dos conjuntos de datos separados, uno para cada antibiótico, porque la resistencia a ciprofloxacina y la resistencia a cefotaxima no necesariamente dependen de los mismos genes. En cada caso, la variable que se quería predecir fue el fenotipo antimicrobiano, es decir, si el genoma correspondía a una cepa resistente o susceptible. Como variables de entrada se usó la presencia o ausencia de genes relacionados con resistencia antimicrobiana.

Los datos se obtuvieron de BV-BRC usando el taxón *Escherichia coli*. Primero se descargaron registros de fenotipo antimicrobiano desde la sección AMR Phenotypes para ciprofloxacina y cefotaxima. En esta parte solo se filtraron los registros clasificados como *Resistant* o *Susceptible*, ya que el proyecto se trabajó como una clasificación binaria, por lo que también se excluyeron los registros *Intermediate*, las predicciones computacionales y las entradas que no estuvieran sustentadas por evidencia de laboratorio. Este filtro fue necesario porque el objetivo era entrenar los modelos con datos fenotípicos reales y no con etiquetas que ya hubieran sido generadas por otra herramienta predictiva.

Después de descargar y unir los archivos de fenotipos, se hizo una limpieza para conservar únicamente los datos de los dos antibióticos seleccionados. También se revisaron las combinaciones repetidas de genoma y antibiótico, porque podía ocurrir que un mismo genoma tuviera más de un registro para el mismo antibiótico. La idea fue que cada genoma tuviera una sola etiqueta fenotípica por antibiótico. Cuando una combinación de *genome_id* y antibiótico tenía etiquetas contradictorias, se eliminó del análisis, ya que mantener esos casos podía meter ruido en la variable de respuesta. Al final de este proceso quedaron 7,313 genomas para ciprofloxacina, de los cuales 1,851 fueron resistentes y 5,462 susceptibles. Para cefotaxima quedaron 6,590 genomas, con 1,272 resistentes y 5,318 susceptibles.

Para la parte genética, se descargaron genes AMR desde la sección Specialty Genes de BV-BRC, filtrando la categoría *Antibiotic Resistance*. En este paso no se seleccionaron únicamente genes específicos para ciprofloxacina o cefotaxima, porque se buscó conservar un perfil amplio de genes de resistencia. Esto era útil porque una bacteria puede presentar varios mecanismos al mismo tiempo, no solo el mecanismo más directo para un antibiótico. Por ejemplo, podían aparecer genes relacionados con β -lactamasas, genes vinculados con quinolonas, bombas de expulsión u otros determinantes de resistencia. Después de descargar esta tabla, se filtró para conservar solamente los *genome_id* que también estaban presentes en los fenotipos ya limpios.

La tabla original de genes no estaba lista todavía para usarse en modelos. Al inicio tenía un formato largo, es decir, podían aparecer varias filas para un mismo genoma dependiendo de los genes detectados. Para transformarla en un formato útil para aprendizaje automático, se convirtió en una matriz de presencia y ausencia. En esta matriz, cada fila representó un genoma de *E. coli* y cada columna representó un gen AMR. Si el gen estaba presente en un genoma, se marcó con 1; si no estaba, se marcó con 0. Después, esta matriz se unió con la tabla de fenotipos usando el *genome_id*, y así se generó un dataset independiente para ciprofloxacina y otro para cefotaxima.

Antes de entrenar los modelos, se preparó una versión *model_ready* de cada dataset. Esta versión fue la que se usó directamente para el análisis. En ella se eliminaron genes casi constantes o con muy poca variación entre genomas, porque esas columnas aportan poca información. Por ejemplo, si un gen aparece en casi todos los genomas o no aparece casi en ninguno, el modelo tiene menos posibilidad de usarlo para separar resistentes y susceptibles. Además, conservar demasiadas columnas poco informativas puede aumentar el ruido durante el entrenamiento. Después de este filtrado, el dataset de ciprofloxacina quedó con 633 variables AMR, mientras que el de cefotaxime quedó con 560 variables AMR. La composición final de los conjuntos de datos usados en el análisis se resume en la Tabla 1. Cabe destacar que los genes AMR corresponden a variables binarias de presencia/ausencia conservadas después del filtrado para generar los datasets *model_ready*.

Antibiótico	Genomas totales	Resistentes	Susceptibles	Genes AMR <i>model_ready</i>
Ciprofloxacina	7,313	1,851	5,462	633
Cefotaxime	6,590	1,272	5,318	560

Tabla 1. Composición final de los conjuntos de datos usados para el análisis predictivo.

La variable objetivo se codificó de forma binaria. Los genomas resistentes se marcaron con 1 y los susceptibles con 0. Esta codificación permitió que los modelos trabajaran con una respuesta numérica. También se tomó en cuenta que en ambos antibióticos había más genomas susceptibles que resistentes. Este desbalance podía afectar el desempeño, porque un modelo podría aprender mejor la clase más abundante y fallar más en la clase resistente. Por eso, además de revisar la exactitud general, se usó como métrica principal la *balanced accuracy*, que considera el desempeño del modelo en ambas clases, y no solo el número total de aciertos.

Para cada antibiótico, los datos se dividieron en un conjunto de entrenamiento y un conjunto de prueba retenido. El conjunto de prueba correspondió al 20% de los datos y

se dejó separado hasta la evaluación final. Esto se hizo para tener una forma de revisar el desempeño del modelo con datos que no hubiera usado durante el entrenamiento. La división fue estratificada, lo que significa que se intentó conservar una proporción similar de resistentes y susceptibles tanto en entrenamiento como en prueba. Con el conjunto de entrenamiento se compararon varios modelos de aprendizaje automático supervisado: regresión logística balanceada, random forest balanceado, XGBoost ponderado y un perceptrón multicapa o MLP.

Cada modelo se incluyó por una razón distinta. La regresión logística se usó porque es un modelo más sencillo de interpretar y permite revisar qué variables pesan más en la clasificación. Random forest se incluyó porque trabaja con muchos árboles de decisión y puede detectar relaciones más complejas entre variables. XGBoost también está basado en árboles, pero los construye de forma secuencial, intentando corregir errores en cada paso. El MLP se agregó como modelo de red neuronal, para comparar si un enfoque de este tipo podía funcionar mejor o de manera similar a los otros modelos.

La comparación de modelos se hizo usando validación cruzada estratificada y repetida dentro del conjunto de entrenamiento. En términos generales, esto consiste en dividir varias veces los datos de entrenamiento en partes más pequeñas: unas se usan para entrenar y otras para validar. Esto ayuda a tener una idea más estable del desempeño del modelo, porque no depende de una sola división aleatoria. Además, para los modelos principales se realizó una búsqueda de hiperparámetros.

Después de comparar los modelos durante el entrenamiento, el desempeño final se evaluó en el conjunto retenido del 20%. En esta evaluación se revisaron varias métricas: *accuracy*, *balanced accuracy*, ROC-AUC, F1 para la clase resistente, *recall* resistente, especificidad susceptible y número de falsos susceptibles. Se puso especial atención en los falsos susceptibles, porque son casos en los que el genoma era realmente resistente, pero el modelo lo clasificó como susceptible. Aunque este análisis no se planteó como una herramienta clínica, ese tipo de error es relevante para interpretar el desempeño del modelo.

Además de revisar las métricas, también se consideró la parte biológica de las variables más influyentes. Para ciprofloxacina se revisó si los genes o señales más importantes tenían relación con mecanismos descritos para quinolonas y fluoroquinolonas, como alteraciones asociadas con *gyrA*, *parC* y *parE*. Para cefotaxima se revisó si las señales principales correspondían a genes relacionados con β -lactamasas, como familias CTX-M y CMY.

Finalmente, se hizo un análisis adicional considerando el método fenotípico de laboratorio. Esto se realizó para revisar si el desempeño del modelo se mantenía al

separar los datos según el tipo de prueba usada para medir resistencia, como *disk diffusion*, *broth dilution*, MIC o *agar dilution*, dependiendo del antibiótico.




Figura 1. Flujo general del análisis genómico predictivo. El esquema resume el proceso seguido desde la obtención de datos en BV-BRC hasta la interpretación biológica de los modelos. Primero se filtraron los fenotipos AMR de *E. coli* para ciprofloxacin y cefotaxime, conservando únicamente registros Resistant/Susceptible con evidencia de laboratorio. Después se integraron genes AMR de la categoría Antibiotic Resistance, se construyeron matrices binarias de presencia/ausencia y se generaron datasets **model_ready** por antibiótico. Finalmente, se compararon modelos supervisados y se evaluó su desempeño mediante métricas de clasificación e interpretación biológica.

Resultados

La comparación general de los modelos se muestra en la Tabla 2. En ciprofloxacina, la regresión logística balanceada obtuvo una balanced accuracy de 0.844, un ROC-AUC de 0.906 y un F1 para resistentes de 0.759. Random forest tuvo el ROC-AUC más alto, con 0.922, pero su balanced accuracy fue un poco menor que la de la regresión logística. XGBoost tuvo un desempeño cercano, aunque tampoco superó a la regresión logística en la métrica principal. El MLP ponderado, calculado como promedio de siete semillas, alcanzó una balanced accuracy de 0.835.

Antibiótico	Modelo	Balanced accuracy	ROC-AUC	F1 resistente	Recall resistente	Falsos susceptibles	Falsos resistentes
Ciprofloxacina	Regresión logística balanceada	0.844	0.906	0.759	0.784	80	104
Ciprofloxacina	Random forest balanceado	0.837	0.922	0.753	0.765	87	99
Ciprofloxacina	XGBoost ponderado	0.836	0.907	0.753	0.759	89	95
Ciprofloxacina	MLP ponderado	0.835	0.903	0.734	0.797	75	139
Cefotaxime	Regresión logística balanceada	0.827	0.893	0.719	0.724	70	74
Cefotaxime	Random forest balanceado	0.791	0.879	0.623	0.728	69	155
Cefotaxime	XGBoost ponderado	0.810	0.886	0.690	0.697	77	82
Cefotaxime	MLP ponderado (promedio 7 semillas)	0.818	0.893	0.676	0.744	65	116

Tabla 2. Desempeño de los modelos en el conjunto retenido de prueba.

En cefotaxime también se seleccionó la regresión logística balanceada. Este modelo obtuvo una balanced accuracy de 0.827 y un ROC-AUC de 0.893. El MLP tuvo un recall resistente un poco mayor, con 0.744, y redujo los falsos susceptibles de 70 a 65 en comparación con la regresión logística. Sin embargo, también aumentó los falsos resistentes de 74 a 116, por lo que clasificó como resistentes más genomas que en realidad eran susceptibles.

La comparación de balanced accuracy entre los cuatro modelos se resume en la Figura 2. En ambos antibióticos, la regresión logística balanceada quedó en primer lugar bajo esta métrica. En ciprofloxacina las diferencias fueron pequeñas, porque random forest, XGBoost y MLP tuvieron valores cercanos. En cefotaxime, la diferencia fue más clara, sobre todo porque random forest tuvo una balanced accuracy más baja que los demás modelos.




Figura 2. En la gráfica se compara el desempeño balanceado de regresión logística, random forest, XGBoost y MLP en ambos antibióticos. En los dos casos, la regresión logística balanceada tuvo el mejor valor de balanced accuracy, aunque en ciprofloxacina los demás modelos quedaron relativamente cerca.

También se revisaron los falsos susceptibles de cada modelo, como se muestra en la Figura 3. Este tipo de error corresponde a genomas resistentes que fueron clasificados como susceptibles. En ciprofloxacina, el MLP tuvo el menor número de falsos susceptibles, con 75, seguido por la regresión logística con 80. En cefotaxime ocurrió algo similar, ya que el MLP redujo los falsos susceptibles a 65 y la regresión logística tuvo 70.




Figura 3. Los falsos susceptibles corresponden a genomas resistentes que fueron clasificados como susceptibles. El MLP redujo ligeramente este tipo de error en ambos antibióticos.

Las matrices de confusión de los modelos seleccionados se muestran en la Figura 4. Estas matrices ayudan a ver de forma más directa cuántos genomas fueron clasificados correctamente y cuántos quedaron en cada tipo de error. Para ciprofloxacina, la regresión logística balanceada clasificó correctamente 989 genomas susceptibles y 290 resistentes. Los errores fueron 104 falsos resistentes y 80 falsos susceptibles. En cefotaxime, el mismo modelo clasificó correctamente 990 susceptibles y 184 resistentes, con 74 falsos resistentes y 70 falsos susceptibles.




Figura 4. Matrices de confusión de los modelos seleccionados. En ambos casos, se observa que el modelo reconoció mejor la clase susceptible que la resistente, lo cual puede relacionarse con que había más genomas susceptibles desde el inicio.

Después de revisar el desempeño de clasificación, se analizaron las variables AMR más estables en los modelos seleccionados con el fin de revisar si los genes que aparecían con más peso tenían sentido con lo que se conoce sobre los antibióticos. En ciprofloxacin, los genes más estables se presentan en la Figura 5. Las señales principales estuvieron relacionadas con resistencia a quinolonas y fluoroquinolonas, particularmente variables asociadas con *parC*, *gyrA* y *parE*.




Figura 5. Top 10 de los genes AMR más estables en ciprofloxacin. La estabilidad indica que esas variables aparecieron de forma repetida entre las más influyentes durante las repeticiones del análisis.

Para cefotaxime, los genes más estables se muestran en la Figura 6. En este caso, las variables con mayor estabilidad correspondieron principalmente a genes o familias de β -lactamasas, como *ctx-m-15*, *ctx-m_family*, *ctx-m-14* y *cmy-2*.




Figura 6. Top 10 de los genes AMR más estables para cefotaxime. Las variables más estables estuvieron dominadas por genes o familias de β -lactamasas, principalmente CTX-M y CMY.

Como análisis adicional, se evaluó si el desempeño del modelo cambiaba dependiendo del método fenotípico de laboratorio. Para esto se hizo una validación tipo leave-method-out. En esta prueba, cada método de laboratorio se dejó fuera del entrenamiento y después se usó como conjunto de prueba. El objetivo fue revisar si el modelo seguía funcionando cuando se evaluaba en datos obtenidos con un método que no había visto durante el entrenamiento. Los resultados se presentan en la Tabla 3.

Antibiótico	Método dejado fuera para prueba	n	Resistentes	Balanced accuracy	ROC-AUC	Recall resistente	Falsos susceptibles	Falsos resistentes

Ciprofloxacin	Broth dilution	2,494	960	0.786	0.858	0.782	209	322
Ciprofloxacin	Disk diffusion	3,709	675	0.815	0.869	0.716	192	257
Ciprofloxacin	MIC	1,074	186	0.813	0.863	0.720	52	83
Cefotaxime	Agar dilution	1,015	81	0.821	0.878	0.691	25	47
Cefotaxime	Broth dilution	2,206	829	0.768	0.829	0.651	289	160
Cefotaxime	Disk diffusion	3,326	330	0.801	0.848	0.721	92	357

Tabla 3. Validación leave-method-out por método fenotípico de laboratorio.

La variación del desempeño bajo la validación leave-method-out se resume en la Figura 7. En ciprofloxacin, la balanced accuracy se mantuvo entre 0.786 y 0.815, con valores de ROC-AUC entre 0.858 y 0.869, lo que representa una ligera disminución en su desempeño. En cefotaxime, los resultados fueron más variables, con balanced accuracy entre 0.768 y 0.821. El caso más difícil fue cefotaxime evaluado en broth dilution, donde el recall resistente fue de 0.651 y se observaron 289 falsos susceptibles.




Figura 7. Robustez por método de laboratorio. La gráfica muestra que el desempeño se mantuvo en un rango aceptable al evaluar métodos de laboratorio no vistos durante el entrenamiento, aunque hubo variación entre antibióticos y métodos. El escenario más difícil fue cefotaxime evaluado en broth dilution, con una balanced accuracy menor que las demás condiciones.

Análisis

En ambos antibióticos, los modelos alcanzaron valores de *balanced accuracy* superiores a 0.50, que sería el valor esperado para una clasificación sin señal útil en un problema binario. Esto sugiere que la presencia y ausencia de genes AMR sí contenía información relacionada con el fenotipo resistente o susceptible. A partir de esto, el análisis puede interpretarse en dos niveles: primero, como una comparación de los modelos predictivos; y después, como una forma de revisar si las variables que más influyeron tienen sentido con los mecanismos biológicos conocidos.

La comparación entre modelos mostró que la regresión logística balanceada fue el modelo más consistente para ambos antibióticos. Esto puede parecer llamativo porque también se incluyeron modelos más complejos, como random forest, XGBoost y MLP. Sin embargo, un modelo más complejo no necesariamente funciona mejor si las variables ya contienen señales relativamente claras, algo que también se ha discutido

en revisiones sobre aprendizaje automático aplicado a resistencia antimicrobiana (Kim et al., 2022). En este caso, los genes AMR en formato de presencia/ausencia probablemente tenían relaciones bastante directas con algunos fenotipos de resistencia, sobre todo en cefotaxime, donde las β -lactamasas tienen un papel claro en la resistencia a cefalosporinas (Bevan et al., 2017; Bush & Bradford, 2016). La regresión logística pudo aprovechar esas diferencias sin necesitar una estructura tan elaborada. Además, al ser un modelo más interpretable, permitió revisar con más facilidad qué variables estaban contribuyendo a la clasificación.

En ciprofloxacina, los cuatro modelos tuvieron valores de *balanced accuracy* bastante cercanos. La regresión logística quedó ligeramente arriba, pero random forest, XGBoost y MLP no se alejaron demasiado. Esto sugiere que la señal disponible para este antibiótico era relativamente estable entre modelos, es decir, no dependía demasiado de una arquitectura específica. En cefotaxime, la diferencia fue más marcada, sobre todo porque random forest tuvo un desempeño menor bajo *balanced accuracy*. Esto podría indicar que la clasificación de cefotaxime fue más sensible al desbalance de clases o a la forma en que cada modelo manejó combinaciones de genes. También puede relacionarse con que la resistencia a cefotaxime depende de familias de β -lactamasas que pueden estar anotadas de varias formas, lo que puede generar señales repetidas o parcialmente redundantes.

El MLP permitió comparar los modelos con una red neuronal. En ambos antibióticos redujo ligeramente los falsos susceptibles, pero también aumentó los falsos resistentes. En otras palabras, se volvió más sensible para identificar resistentes, pero a costa de perder parte de su capacidad para reconocer susceptibles. Es por ello que no fue seleccionado como modelo final, aunque sí mostró que una red neuronal podía capturar parte de la señal. Si el objetivo futuro fuera reducir al máximo los falsos susceptibles, se podría explorar un ajuste del umbral de decisión o una función de costo que penalice más ese tipo de error.

Las matrices de confusión ayudan a entender mejor esta diferencia entre métricas. En los modelos seleccionados se observó que la clase susceptible fue reconocida con mayor facilidad que la resistente. Esto puede explicarse en parte por el hecho de que había más ejemplos de la clase de susceptibles durante el entrenamiento, pero también puede tener una explicación biológica. La susceptibilidad puede estar relacionada con la ausencia de ciertos mecanismos fuertes de resistencia, mientras que la resistencia puede aparecer por varias rutas distintas. Dos cepas resistentes pueden no compartir exactamente los mismos genes o mutaciones. Así, la clase resistente puede ser más heterogénea y, por lo tanto, más difícil de aprender para el modelo.

En ciprofloxacina, esta heterogeneidad es especialmente importante. Como se mencionó anteriormente, ciprofloxacina pertenece a las fluoroquinolonas y actúa sobre enzimas relacionadas con el manejo del ADN bacteriano, como la ADN girasa y la topoisomerasa IV (Hooper & Jacoby, 2016). Por eso, las señales relacionadas con *gyrA*, *parC* y *parE* tienen sentido biológico. Estos genes codifican componentes de los blancos del antibiótico, y ciertas mutaciones pueden reducir la unión del fármaco (Hooper & Jacoby, 2016). Que el modelo haya recuperado variables relacionadas con estos genes sugiere que parte de la clasificación se apoyó en mecanismos esperados. Sin embargo, el análisis tiene una limitación aquí, ya que al trabajar con presencia/ausencia de genes AMR, puede no capturar con suficiente detalle todas las mutaciones puntuales específicas. Para fluoroquinolonas, esas mutaciones pueden ser más informativas que solo la presencia del gen, porque casi todas las cepas tienen genes como *gyrA* o *parC*, pero no todas tienen las variantes asociadas con resistencia.

Además, en los genes estables de ciprofloxacina aparecieron señales que no corresponden al mecanismo clásico de resistencia a fluoroquinolonas, como variables relacionadas con *ctx-m-15*, *blaEC* o *catB3*. No sería adecuado afirmar que esos genes causan resistencia a ciprofloxacina de manera directa, aunque pueden estar funcionando como señales indirectas de co-resistencia, multiresistencia, plásmidos compartidos o linajes bacterianos donde varias resistencias aparecen juntas (Partridge et al., 2018; Her & Wu, 2018). En *E. coli*, los genes de resistencia pueden acumularse en ciertos fondos genéticos o elementos móviles, de manera que un gen relacionado con β -lactámicos puede aparecer con frecuencia en cepas que también son resistentes a fluoroquinolonas (Partridge et al., 2018; Her & Wu, 2018). En ese caso, el modelo puede no estar identificando necesariamente una causa directa, sino una asociación útil para clasificar.

De esto surge la necesidad de abordar la diferencia entre variable predictiva y mecanismo causal. Un modelo puede usar una variable porque le ayuda a separar resistentes y susceptibles, aunque esa variable no sea la razón biológica principal de la resistencia (Kim et al., 2022; Her & Wu, 2018). Es por ello que los genes más estables deben interpretarse como señales asociadas al fenotipo, pero no como prueba directa de causalidad. Para mejorar esta parte en futuros análisis, sería útil agrupar genes por mecanismo o por familia. Por ejemplo, varias anotaciones de CTX-M podrían representar formas muy cercanas de una misma señal biológica. Si se agrupan por familia, la interpretación sería más directa y se reduciría el riesgo de pensar que hay muchas variables independientes cuando en realidad varias describen un mecanismo parecido.

En cefotaxima, la interpretación biológica es más directa. Las variables más estables estuvieron dominadas por genes o familias de β -lactamasas, como *ctx-m-15*,

ctx-m_family, *ctx-m-14* o *cmv-2*. Esto coincide con el mecanismo esperado, ya que cefotaxime es una cefalosporina de tercera generación y las β -lactamasas pueden hidrolizar antibióticos β -lactámicos. Las enzimas tipo CTX-M se han reportado ampliamente en *E. coli* resistente a cefalosporinas de tercera generación, mientras que CMY-2 forma parte de las β -lactamasas tipo AmpC, que también pueden contribuir a la resistencia frente a cefalosporinas (Bevan et al., 2017; Bush & Bradford, 2016). En este caso, el modelo parece haber usado señales más directamente relacionadas con el antibiótico evaluado.

La comparación entre ambos antibióticos muestra que no todos los problemas de predicción de resistencia son iguales. Para cefotaxime, una matriz de presencia/ausencia de genes AMR parece ajustarse bien porque muchos mecanismos dependen de genes adquiridos, como β -lactamasas. En ciprofloxacina, en cambio, las mutaciones puntuales en blancos cromosómicos son muy relevantes, por lo que una tabla de presencia/ausencia puede ser insuficiente (Hooper & Jacoby, 2016; Bevan et al., 2017; Bush & Bradford, 2016).

Al comparar estos resultados con otros estudios, se observa que el enfoque usado aquí entra dentro de una línea común en la predicción genómica de resistencia. Revisiones como la de Kim et al. (2022) señalan que los modelos de aprendizaje automático pueden usar genes, variantes o composición genómica para predecir resistencia antimicrobiana. Otros trabajos con *E. coli* han usado datos de genoma completo, SNPs o pangenomas, y en algunos casos los modelos complejos alcanzan desempeños muy altos (Her & Wu, 2018; Ren et al., 2022). La diferencia es que este proyecto se enfocó en genes AMR anotados, lo cual hizo el análisis más interpretable, pero también más limitado. Usar todo el genoma podría mejorar la predicción, aunque haría más difícil distinguir qué señales son biológicamente claras y cuáles solo son marcadores de linaje.

La prueba *leave-method-out* agregó una evaluación importante al responder la cuestión de si el modelo funcionaba solo en una partición aleatoria o si seguía funcionando cuando cambiaba el método fenotípico de laboratorio. Esto es más complicado para el modelo porque se enfrenta a datos medidos de una manera que no vio antes. Por eso era esperable que el desempeño bajara un poco.

Sin embargo, la disminución observada en *leave-method-out* no significa necesariamente que el modelo haya fallado. Los métodos fenotípicos como *disk diffusion*, *broth dilution*, MIC o *agar dilution* no miden exactamente igual la susceptibilidad. Todos buscan clasificar si una bacteria es resistente o susceptible, pero lo hacen con procedimientos distintos (EUCAST, 2024). Además, pueden provenir de laboratorios, años, estudios o criterios de interpretación diferentes. Por eso, el método

de laboratorio puede introducir variación en la etiqueta fenotípica. Puede ser que el genoma sí presente una señal, pero si el fenotipo se mide de forma distinta o si hay cepas cerca del punto de corte, el modelo puede tener más dificultad para clasificar correctamente.

El caso más difícil fue cefotaxime evaluado en *broth dilution*. Una posible explicación es que ese subconjunto tuviera una composición diferente de genomas, quizá con más resistentes, con linajes distintos o con combinaciones de β -lactamasas más variadas. También es posible que el método capture mejor diferencias cuantitativas que después se reducen a una etiqueta binaria. Cuando una cepa queda cerca del límite entre susceptible y resistente, pequeñas diferencias en la medición pueden cambiar la categoría final, ya que la interpretación depende de puntos de corte definidos para cada antibiótico y método (EUCAST, 2024). Esto introduce ruido para el modelo, porque la etiqueta que intenta aprender no siempre representa una separación biológica completamente definida.

Una limitación general del trabajo es que los datos provienen de BV-BRC. Esta base de datos es útil porque reúne genomas, fenotipos y anotaciones (Olson et al., 2023), pero no necesariamente representa de forma equilibrada toda la diversidad de *E. coli*. Algunos países, laboratorios, años, tipos de muestra o linajes pueden estar más representados que otros, una limitación relacionada con problemas de generalización descritos en modelos genómicos de AMR (Kim et al., 2022; Nsubuga et al., 2024). Esto puede influir en el modelo porque, si ciertos linajes resistentes aparecen con mucha frecuencia, el algoritmo puede aprender señales propias de esos linajes además de señales relacionadas con resistencia. Esto puede ocasionar que el modelo funcione bien dentro del conjunto analizado, pero no necesariamente de la misma manera en una colección independiente de otro origen.

Esta limitación se relaciona con la estructura poblacional de *E. coli*. Las cepas no son independientes entre sí, porque algunas están más emparentadas que otras. Esto puede afectar la generalización de los modelos cuando se aplican a colecciones con distinta composición genética o geográfica (Her & Wu, 2018; Nsubuga et al., 2024). Si una familia de cepas comparte genes AMR, plásmidos y fenotipo resistente, el modelo puede interpretar esos genes como señales muy fuertes. El problema es que no siempre se puede saber si la variable es causal o si solo está acompañando a un linaje resistente. Para mejorar esto, sería útil agregar información de filogrupo, secuenciotipo o distancia genómica entre cepas. También se podría hacer una validación bloqueada por linaje, que consistiría en entrenar con ciertos linajes y probar con otros. Si el modelo mantiene desempeño en ese escenario, habría más confianza en que aprendió señales generales de resistencia y no solo características de grupos específicos.

Otra limitación es que la información genética se redujo a presencia y ausencia de genes AMR. Esta representación fue práctica y permitió construir modelos que fueran claros, aunque simplificó gran parte de la variabilidad biológica del sistema. Un gen puede estar presente, pero eso no indica si está completo, si se expresa, si tiene una variante funcional, si está en un plásmido activo o si aparece junto con otros genes necesarios para generar resistencia (Feldgarden et al., 2021; Kim et al., 2022). También se pierde información sobre el número de copias y sobre el contexto genómico. En bacterias, el contexto es importante, ya que un mismo gen puede tener efectos distintos dependiendo de su promotor, del elemento móvil donde se encuentra o de otros mecanismos presentes en la cepa.

Con base en ello, una propuesta de mejora sería construir modelos con varios niveles de información. Para ciprofloxacina, además de genes AMR, sería útil incluir mutaciones específicas en regiones relacionadas con resistencia a quinolonas, sobre todo en *gyrA*, *parC* y *parE*. Para cefotaxime, sería útil distinguir mejor entre familias de β -lactamasas, variantes específicas, genes AmpC y posibles combinaciones con pérdida de permeabilidad o bombas de expulsión. También podrían incorporarse variables de pangenoma, SNPs o k-mers, aunque esto debería hacerse tratando de no perder demasiada interpretabilidad (Her & Wu, 2018; Ren et al., 2022). Una opción equilibrada sería empezar con variables biológicamente guiadas, en lugar de meter todo el genoma sin filtrado.

Otra propuesta es ajustar los umbrales de clasificación. En este proyecto se eligió el modelo por desempeño balanceado general, pero el análisis del MLP mostró que es posible reducir falsos susceptibles a costa de aumentar falsos resistentes. Dependiendo del objetivo, ese intercambio puede ser aceptable o no. Si se quisiera priorizar la detección de resistentes, se podría bajar el umbral para clasificar como resistente o usar funciones de costo que penalicen más los falsos susceptibles. Si se quisiera evitar clasificar erróneamente susceptibles como resistentes, se podría hacer lo contrario.

Finalmente, una validación externa sería una mejora importante. El análisis *leave-method-out* fue una buena aproximación como revisión interna, pero todavía usa datos provenientes del mismo marco general de BV-BRC. Se podría probar el modelo en una colección independiente de *E. coli*, obtenida de otra base de datos, otro laboratorio o un estudio publicado con fenotipos comparables. Si el desempeño se mantiene, la confianza en el modelo aumentaría. Si baja, también sería informativo, porque permitiría identificar qué tanto dependía el modelo de la composición original de los datos.

Conclusiones

El análisis permitió evaluar si la presencia y ausencia de genes AMR podía usarse para clasificar genomas de *Escherichia coli* como resistentes o susceptibles a ciprofloxacina y cefotaxima. En ambos antibióticos, los modelos mostraron un desempeño superior al esperado para una clasificación sin señal útil, lo que sugiere que la información genética usada sí estuvo relacionada con el fenotipo antimicrobiano.

La regresión logística balanceada fue el modelo más adecuado para el análisis principal, ya que presentó un desempeño estable, permitió manejar el desbalance entre resistentes y susceptibles y facilitó la interpretación de las variables. Aunque random forest, XGBoost y MLP también lograron clasificar los genomas, no mejoraron de forma clara la *balanced accuracy*. El MLP redujo ligeramente los falsos susceptibles, pero aumentó los falsos resistentes, por lo que no fue seleccionado como modelo final.

Los genes más estables tuvieron relación con mecanismos conocidos de resistencia. En ciprofloxacina aparecieron señales asociadas con *gyrA*, *parC* y *parE*, mientras que en cefotaxima destacaron genes de β -lactamasas como *ctx-m* y *cmy*. Esto apoyó la interpretación biológica del modelo, aunque no demuestra causalidad directa. Además, la validación por método de laboratorio mostró que el desempeño podía variar según la forma en que se obtuvo el fenotipo, pero que la señal predictiva no dependía solamente de una partición aleatoria de los datos.

Finalmente, aunque los genes AMR en formato de presencia/ausencia pueden ser útiles para un análisis predictivo exploratorio de resistencia en *E. coli*, para mejorar el enfoque sería necesario incluir mutaciones específicas, controlar la estructura poblacional de las cepas y validar el modelo en bases de datos externas.

Referencias

- Bevan, E. R., Jones, A. M., & Hawkey, P. M. (2017). Global epidemiology of CTX-M β -lactamasas: Temporal and geographical shifts in genotype. *Journal of Antimicrobial Chemotherapy*, 72(8), 2145–2155. <https://doi.org/10.1093/jac/dkx146>
- Bush, K., & Bradford, P. A. (2016). β -Lactams and β -lactamase inhibitors: An overview. *Cold Spring Harbor Perspectives in Medicine*, 6(8), a025247. <https://doi.org/10.1101/cshperspect.a025247>
- Centers for Disease Control and Prevention. (2024). *About Escherichia coli infection*. <https://www.cdc.gov/ecoli/about/index.html>

European Centre for Disease Prevention and Control. (2025). *Surveillance of antimicrobial resistance in Europe, 2024 data*. ECDC. <https://www.ecdc.europa.eu/en/publications-data/surveillance-antimicrobial-resistance-europe-2024-data>

European Committee on Antimicrobial Susceptibility Testing. (2024). *Breakpoint tables for interpretation of MICs and zone diameters: Version 14.0*. EUCAST. <https://www.eucast.org>

Feldgarden, M., Brover, V., Gonzalez-Escalona, N., Frye, J. G., Haendiges, J., Haft, D. H., Hoffmann, M., Pettengill, J. B., Prasad, A. B., Tillman, G. E., Tyson, G. H., & Klimke, W. (2021). AMRFinderPlus and the Reference Gene Catalog facilitate examination of the genomic links among antimicrobial resistance, stress response, and virulence. *Scientific Reports*, 11, 12728. <https://doi.org/10.1038/s41598-021-91456-0>

Her, H.-L., & Wu, Y.-W. (2018). A pan-genome-based machine learning approach for predicting antimicrobial resistance activities of the *Escherichia coli* strains. *Bioinformatics*, 34(13), i89–i95. <https://doi.org/10.1093/bioinformatics/bty276>

Hooper, D. C., & Jacoby, G. A. (2016). Topoisomerase inhibitors: Fluoroquinolone mechanisms of action and resistance. *Cold Spring Harbor Perspectives in Medicine*, 6(9), a025320. <https://doi.org/10.1101/cshperspect.a025320>

Kim, J. I., Maguire, F., Tsang, K. K., Gouliouris, T., Peacock, S. J., McAllister, T. A., McArthur, A. G., & Beiko, R. G. (2022). Machine learning for antimicrobial resistance prediction: Current practice, limitations, and clinical perspective. *Clinical Microbiology Reviews*, 35(3), e00179-21. <https://doi.org/10.1128/cmr.00179-21>

Nsubuga, M., Galiwango, R., Jjingo, D., & Mboowa, G. (2024). Generalizability of machine learning in predicting antimicrobial resistance in *E. coli*: A multi-country case study in Africa. *BMC Genomics*, 25, 287. <https://doi.org/10.1186/s12864-024-10214-4>

Olson, R. D., Assaf, R., Brettin, T., Conrad, N., Cucinell, C., Davis, J. J., Dempsey, D. M., Dickerman, A., Dietrich, E. M., Kenyon, R. W., Kuscuoglu, M., Lefkowitz, E. J., Lu, J., Machi, D., Macken, C., Mao, C., Niewiadomska, A., Nguyen, M., Olsen, G. J., ... Scheuermann, R. H. (2023). Introducing the Bacterial and Viral Bioinformatics Resource Center (BV-BRC): A resource combining PATRIC, IRD and ViPR. *Nucleic Acids Research*, 51(D1), D678–D689. <https://doi.org/10.1093/nar/gkac1003>

Partridge, S. R., Kwong, S. M., Firth, N., & Jensen, S. O. (2018). Mobile genetic elements associated with antimicrobial resistance. *Clinical Microbiology Reviews*, 31(4), e00088-17. <https://doi.org/10.1128/CMR.00088-17>

Ren, Y., Chakraborty, T., Doijad, S., Falgenhauer, L., Falgenhauer, J., Goesmann, A., Hauschild, A.-C., Schwengers, O., Heider, D., & Sztyler, T. (2022). Prediction of antimicrobial resistance based on whole-genome sequencing and machine learning. *Bioinformatics*, 38(2), 325–334. <https://doi.org/10.1093/bioinformatics/btab681>

World Health Organization. (2018, February 7). *E. coli*. <https://www.who.int/news-room/fact-sheets/detail/e-coli>

World Health Organization. (2023). *Antimicrobial resistance*. <https://www.who.int/news-room/fact-sheets/detail/antimicrobial-resistance>

World Health Organization. (2025). *Global antibiotic resistance surveillance report 2025*. World Health Organization. <https://www.who.int/publications/i/item/9789240116337>